



Hochschule
Bonn-Rhein-Sieg
University of Applied Sciences

HOCHSCHULE BONN-RHEIN-SIEG

FACHBEREICH INFORMATIK

Exposé zur Bachelorarbeit

Automatisierte Transformation unstrukturierter Produktdaten mittels großer Sprachmodelle

Konzeption, Implementierung und Evaluation eines auf Sprachmodellen basierenden
Ansatzes im Vergleich zu regelbasierten Verfahren

Autor: Fabian Lohoff

Matrikelnummer: 9051803

Unternehmen: snoopmedia GmbH

Bearbeitungszeitraum: Mai 2026 – August 2026

Betreuer: Prof. Dr. Sascha Alda

Fachlicher Betreuer: Ronald Brenner

20. April 2026

Inhaltsverzeichnis

1 Problemstellung	1
2 Fragestellungen	1
3 Zielsetzung	2
4 Grundlagen und Forschungsstand	3
4.1 Datenintegration und automatisierte Extraktionsverfahren	3
4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke	3
5 Methodik	4
6 Evaluierungsstrategie	4
7 Kontext	5
A Vorläufiger Gliederungsentwurf der Thesis	6
B Vorläufiger Zeit- und Aufgabenplan	7
C Vorläufiges Literaturverzeichnis	8

1 Problemstellung

Die zunehmende Digitalisierung und Automatisierung von Geschäftsprozessen führt dazu, dass Unternehmen in großem Umfang Produktdaten aus unterschiedlichen Quellen erfassen und verarbeiten. Insbesondere im Kontext von Web-Crawling entstehen dabei häufig große Mengen an unstrukturierten oder nur schwach strukturierten Textdaten, die für eine Weiterverarbeitung in Informationssystemen zunächst in eine definierte Datenstruktur überführt werden müssen.

Ein zentrales Problem besteht darin, dass diese Rohdaten in der Regel nicht den Anforderungen bestehender Datenbankschemata entsprechen. Dies ist primär auf eine mangelnde Standardisierung zurückzuführen. Dies ist eine der Kernherausforderungen innerhalb der Datenintegration (vgl. Doan et al. 2012, S. 1–15). Zwar existieren mit Initiativen wie schema.org fundierte Ansätze, um einen generischen Standard für die semantische Auszeichnung von Webinhalten zu etablieren (vgl. Guha et al. 2016, S. 44), jedoch findet dieser in der Praxis noch keine flächendeckende Anwendung. Infolgedessen bleibt eine signifikante Heterogenität der Datenquellen bestehen, welche die nahtlose Integration in Informationssysteme erschwert (vgl. Meusel et al. 2015, S. 1).

Die Transformation solcher formlosen Produktinformationen in eine strukturierte und schema-konforme Form erfolgt häufig mittels regelbasierter Ansätze. In der Literatur werden diese oft als Wrapper bezeichnet, die auf spezifische Muster oder Heuristiken angewiesen sind (vgl. Ferrara et al. 2014, S. 9). Diese Verfahren erweisen sich jedoch als äußerst fragil gegenüber variierenden Schreibweisen, uneinheitlichen Formaten sowie semantischen Unterschieden (vgl. Ferrara et al. 2014, S. 12). Insbesondere bei heterogenen Datenquellen stoßen sie an ihre Grenzen, da jede strukturelle Abweichung der Quelle eine manuelle Anpassung der Extraktionsregeln erfordert, was in der Praxis zu einem kaum noch zu bewältigenden Wartungsaufwand führt (vgl. Ferrara et al. 2014, S. 14).

Gleichzeitig eröffnen LLMs neue Möglichkeiten zur semantischen Interpretation und Strukturierung unstrukturierter Daten. Allerdings ist bislang unklar, inwieweit solche Modelle zuverlässig und konsistent in der Lage sind, komplexe Datenstrukturen vollständig und korrekt abzubilden. Die Relevanz dieses Problems ergibt sich aus der zentralen Rolle strukturierter Daten für nachgelagerte Prozesse wie Analyse, Suche oder Integration in bestehende Systeme. Eine fehlerhafte oder inkonsistente Datenüberführung kann zu erheblichen Qualitätseinbußen und ineffizienten Prozessen führen.

Vor diesem Hintergrund stellt sich die Herausforderung, einen Ansatz zu entwickeln, der sowohl die Flexibilität semantischer Modelle nutzt als auch die Anforderungen an Schema-Konformität und Datenqualität erfüllt. Zudem ist zu untersuchen, wie sich ein solcher Ansatz im Vergleich zu klassischen regelbasierten Verfahren verhält und unter welchen Bedingungen ein praktischer Einsatz sinnvoll ist.

2 Fragestellungen

Die Arbeit soll die folgende zentrale Forschungsfrage beantworten:

Wie gut kann ein LLM-basierter Ansatz formloser Produktdaten vollständig und schema-konform in eine bestehende Datenbankstruktur überführen, und wie schneidet dieser im Vergleich zu einem regelbasierten Ansatz für ein ausgewähltes Datenfeld ab?

Daraus ergeben sich folgende Teilfragestellungen:

1. In welchem Maße gelingt es einem LLM-basierten Ansatz, unstrukturierte Produktdaten korrekt und vollständig auf ein vorgegebenes Datenbankschema abzubilden?

2. Wie hoch ist die Schema-Konformität der durch das LLM erzeugten Daten?
3. Wie unterscheidet sich die Extraktionsqualität eines LLM-basierten Ansatzes gegenüber einem regelbasierten Verfahren für ein Referenzdatenfeld?
4. Welche Auswirkungen haben unterschiedliche Datenformate und Schreibweisen auf die Leistungsfähigkeit der Ansätze?
5. Welche Grenzen und potenziellen Fehlerquellen ergeben sich beim Einsatz von LLMs zur strukturierten Datenüberführung?

3 Zielsetzung

Ziel der vorliegenden Arbeit ist die Entwicklung und Evaluation eines Ansatzes zur automatisierten Transformation unstrukturierter Produktdaten in eine bestehende Datenbankstruktur unter Verwendung von LLMs.

Im Mittelpunkt steht die Untersuchung, inwieweit ein LLM-basierter Ansatz in der Lage ist, formlos vorliegende Produktinformationen vollständig, konsistent und schema-konform in eine strukturierte Form zu überführen. Dabei soll insbesondere die Leistungsfähigkeit dieses Ansatzes im Vergleich zu einem regelbasierten Verfahren für ein ausgewähltes Referenzdatenfeld analysiert werden.

Zur Erreichung dieses Ziels werden folgende Teilziele verfolgt:

- Entwicklung eines LLM-basierten Ansatzes zur vollständigen Abbildung unstrukturierter Produktdaten
- Implementierung eines regelbasierten Vergleichsansatzes für ein Referenzdatenfeld
- Definition geeigneter Evaluationsmetriken
- Durchführung einer quantitativen Evaluation
- Analyse der Ergebnisse

Abgrenzung des Untersuchungsumfangs:

- Bestandteil der Arbeit ist die Transformation bereits vorhandener Rohdaten.
- Bestandteil der Arbeit ist die Entwicklung und Evaluation eines Mapping-Ansatzes.
- Nicht Bestandteil der Arbeit ist die Entwicklung eines Crawling-Systems.
- Nicht Bestandteil der Arbeit ist die Erweiterung des Datenbankschemas.

4 Grundlagen und Forschungsstand

4.1 Datenintegration und automatisierte Extraktionsverfahren

In einer Vielzahl datengetriebener Anwendungen liegen Informationen initial in unstrukturierter oder schwach strukturierter Form vor, beispielsweise als frei formulierte Textbeschreibungen. Für die effiziente Weiterverarbeitung in Informationssystemen ist eine Überführung dieser Daten in strukturierte Formate notwendig, die einem vordefinierten Datenbankschema entsprechen. Die Transformation unstrukturierter Daten in eine strukturierte Form stellt eine Kernherausforderung der Datenintegration dar. Traditionelle Lösungsansätze stützen sich primär auf regelbasierte Verfahren, bei denen spezifische Muster oder Heuristiken zur Extraktion einzelner Datenfelder definiert werden. Diese Verfahren erweisen sich jedoch als defizitär gegenüber variierenden Schreibweisen, mangelnder Standardisierung sowie semantischer Mehrdeutigkeit und verursachen einen erheblichen manuellen Wartungsaufwand.

Mit der Entwicklung von LLM haben sich neue Kapazitäten zur Verarbeitung unstrukturierter Daten eröffnet. Diese Modelle sind in der Lage, natürliche Sprache semantisch zu interpretieren und daraus strukturierte Informationen zu deduzieren. Aktuelle Untersuchungen belegen, dass generative KI-Systeme verstärkt zur automatisierten Datenextraktion herangezogen werden. Die Qualität der extrahierten Informationen wird üblicherweise mittels etablierter Metriken wie *Precision*, *Recall* und dem *F1-Score* quantifiziert. Während *Precision* den Anteil korrekt identifizierter Elemente an der Gesamtmenge der Identifizierungen beschreibt, gibt der *Recall* den Anteil korrekt identifizierter Elemente im Verhältnis zu allen tatsächlich relevanten Elementen an. Der *F1-Score* fungiert als harmonisches Mittel dieser Kennzahlen und dient als aggregiertes Maß der Extraktionsgüte (Jansen et al. 2024, S. 1283). Zudem wird die Übereinstimmung mit Referenzdaten häufig über die prozentuale Übereinstimmung oder den Cohen's Kappa-Koeffizienten validiert, welcher statistische Zufallseffekte berücksichtigt (Jansen et al. 2024, S. 1283).

4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke

Die Effektivität von LLMs wird maßgeblich durch die Gestaltung der Eingabeaufforderungen gesteuert. Dieser als *Prompt Engineering* bezeichnete Prozess umfasst die strategische Formulierung von Anweisungen zur Kontrolle des Modellverhaltens (vgl. Boonstra 2023, S. 5). Relevante Parameter wie die Temperatur beeinflussen dabei maßgeblich, ob die Ausgaben eher deterministisch oder variabel ausfallen (vgl. Boonstra 2023, S. 9f.). Über klassische Strategien wie *Few-Shot-Prompting* hinaus ermöglichen neuere Methoden wie der *Tree of Thoughts* (ToT) eine systematische Exploration des Lösungsraums durch die Zerlegung komplexer Problemstellungen in diskrete Zwischenschritte (vgl. Yao et al. 2023, S. 3f.).

Obgleich LLMs vielversprechende Resultate in der Verarbeitung unstrukturierter Daten liefern, ist die Zuverlässigkeit und Konsistenz bei der vollständigen Abbildung komplexer Datenbankschemata nicht hinreichend belegt. Aktuelle Untersuchungen weisen darauf hin, dass die Extraktionsgüte von einer Vielzahl von Faktoren abhängt und eine systematische Bewertung der Genauigkeit gegenüber menschlich validierten Referenzdaten weiterhin eine Kernherausforderung darstellt (vgl. Jansen et al. 2024, S. 1283). Es mangelt insbesondere an systematischen Vergleichen zwischen LLM-basierten Ansätzen und klassischen regelbasierten Verfahren im Kontext einer schema-konformen Datenüberführung (vgl. Jansen et al. 2024, S. 1283). Hieraus resultiert der wissenschaftliche Bedarf an einer quantitativen Bewertung der Leistungsfähigkeit von LLMs im Vergleich zu etablierten Standardverfahren.

5 Methodik

Zur Beantwortung der formulierten Fragestellungen wird ein kombinierter Ansatz aus konzeptioneller Entwicklung, prototypischer Implementierung sowie quantitativer Evaluation verfolgt.

Zunächst erfolgt eine systematische Analyse der Ausgangsdaten sowie der Anforderungen des zugrunde liegenden Datenbankschemas. Dabei werden die relevanten Datenfelder, deren Struktur sowie notwendige Transformationen identifiziert. Parallel dazu wird eine Literaturrecherche durchgeführt, um bestehende Ansätze zur Verarbeitung und Strukturierung unstrukturierter Daten sowie den Einsatz von LLMs in vergleichbaren Kontexten zu untersuchen.

Aufbauend auf diesen Erkenntnissen wird ein LLM-basierter Ansatz zur Transformation unstrukturierter Produktdaten entwickelt. Dieser umfasst die Konzeption geeigneter Prompts, die Definition von Mapping-Strategien zwischen Eingabedaten und Zielschema sowie die Implementierung eines prototypischen Systems zur automatisierten Datenüberführung.

Ergänzend wird ein regelbasierter Ansatz für ein ausgewähltes Referenzdatenfeld implementiert. Dieser dient als Baseline und ermöglicht einen direkten Vergleich zwischen klassischen deterministischen Verfahren und dem LLM-basierten Ansatz.

Zur Bewertung der Ansätze wird ein geeigneter Datensatz definiert, der als Referenz (Ground Truth) für die Evaluation dient. Auf dieser Basis erfolgt eine quantitative Analyse anhand definierter Key Performance Indicators (KPIs). Dazu zählen insbesondere die Schema-Konformität der erzeugten Daten, die Vollständigkeit der Abbildung sowie die Genauigkeit der Extraktion für das Referenzdatenfeld. Ergänzend werden Effizienzaspekte wie Laufzeit und Verarbeitungskosten betrachtet.

Die Evaluation erfolgt durch einen systematischen Vergleich der Ergebnisse beider Ansätze. Dabei werden sowohl die Qualität der erzeugten Daten als auch die Robustheit gegenüber variierenden Eingabeformaten analysiert. Abschließend werden die Ergebnisse interpretiert und hinsichtlich ihrer praktischen Einsetzbarkeit sowie ihrer Übertragbarkeit auf vergleichbare Anwendungsfälle bewertet.

6 Evaluierungsstrategie

Zur Überprüfung der Zielerreichung und zur Beantwortung der formulierten Fragestellungen wird eine quantitative Evaluierung der entwickelten Ansätze durchgeführt.

Grundlage der Evaluation bildet ein Referenzdatensatz (Ground Truth), der strukturierte Zielwerte für ausgewählte Produktdaten enthält. Dieser dient als Vergleichsbasis zur Bewertung der durch die Ansätze erzeugten Ergebnisse.

Die Evaluierung erfolgt anhand definierter KPIs, die sowohl die Qualität als auch die Strukturtreue der erzeugten Daten abbilden. Dabei orientiert sich die Auswahl an etablierten Dimensionen der Datenqualität (vgl. Wang und Strong 1996, S. 5–33):

- **Schema Compliance Rate:** Anteil der generierten Datensätze, die dem vorgegebenen Datenbankschema entsprechen (Dimension der *Representational Consistency*).
- **Vollständigkeit (Coverage):** Anteil der korrekt befüllten Datenfelder im Verhältnis zu allen erforderlichen Feldern (Dimension der *Completeness*, vgl. Batini und Scannapieco 2016, S. 24).
- **Konsistenz:** Grad der strukturellen und semantischen Einheitlichkeit der erzeugten Daten. Diese Metrik validiert die Widerspruchsfreiheit innerhalb der extrahierten Datensätze (vgl. Batini und Scannapieco 2016, S. 31).

- **Exact Match Rate:** Strikte Übereinstimmung der generierten Werte mit dem Ground Truth. Diese binäre Metrik wird häufig zur Evaluation von Extraktionsaufgaben in strukturierten Benchmarks herangezogen (vgl. Jansen et al. 2024, S. 1283).
- **Precision, Recall und F1-Score:** Aggregierte Maße der Extraktionsgüte, wobei Precision die Genauigkeit und Recall die Trefferquote beschreibt (vgl. Jansen et al. 2024, S. 67f.).
- **Effizienzmetriken:** Analyse der Verarbeitungszeit und der Kosten, was insbesondere im betrieblichen Kontext von hoher Relevanz ist (vgl. Ferrara et al. 2014, S. 3).

Zur Vergleichbarkeit wird sowohl der LLM-basierte Ansatz als auch der regelbasierte Ansatz auf denselben Datensatz angewendet. Die Ergebnisse werden anschließend systematisch gegenübergestellt.

Die Auswertung erfolgt in mehreren Schritten: Zunächst werden die einzelnen Metriken berechnet und quantitativ analysiert. Anschließend werden die Ergebnisse interpretiert, um Unterschiede in der Leistungsfähigkeit, Robustheit gegenüber variierenden Eingabeformaten sowie potenzielle Fehlerquellen zu identifizieren.

Darüber hinaus wird untersucht, inwieweit die Ergebnisse auf andere Datensätze oder Anwendungsfälle übertragbar sind. Dabei werden insbesondere die Grenzen des LLM-basierten Ansatzes hinsichtlich Schema-Konformität, Konsistenz und Reproduzierbarkeit berücksichtigt.

Die Evaluierung ermöglicht somit eine fundierte Bewertung der Frage, ob und unter welchen Bedingungen ein LLM-basierter Ansatz gegenüber klassischen regelbasierten Verfahren Vorteile bietet.

7 Kontext

Die vorliegende Arbeit erfolgt in Kooperation mit der snoopmedia GmbH und befasst sich mit der Verwertung von Ergebnissen sowie Daten aus einem bereits abgeschlossenen Forschungsprojekt. Ziel ist es, die praktische Anwendbarkeit dieser Erkenntnisse im Bereich der automatisierten Strukturierung von Lebensmittel-Produktdaten zu untersuchen und darauf aufbauend einen erweiterten Lösungsansatz zu entwickeln. Im Rahmen dieser Zusammenarbeit stehen bereits durch eine bestehende Crawling-Pipeline erhobene Rohdaten zur Verfügung, die in Form unstrukturierter Lebensmittel-Produktinformationen (wie beispielsweise Bezeichnungen, Zutatenlisten oder Nährwertangaben) vorliegen.

Die Arbeit ist dabei in eine bestehende Systemlandschaft eingebettet, die Anforderungen an die Struktur, Konsistenz und Qualität der Daten stellt. Insbesondere ist die Einhaltung eines vorgegebenen Datenbankschemas eine zentrale Rahmenbedingung. Gleichzeitig ergeben sich aus dem praktischen Anwendungskontext Anforderungen an die Robustheit gegenüber heterogenen Datenquellen sowie an die Effizienz der Verarbeitung.

Darüber hinaus ist die Arbeit durch den begrenzten Bearbeitungszeitraum sowie durch die Verfügbarkeit der zugrunde liegenden Daten eingeschränkt. Die Entwicklung und Evaluation des Lösungsansatzes erfolgt daher auf Basis eines definierten Datenausschnitts aus dem Bereich der Lebensmitteldaten. Die Ergebnisse der Arbeit sollen sowohl wissenschaftliche Erkenntnisse im Bereich der automatisierten Datenstrukturierung liefern als auch einen praktischen Beitrag zur Weiterentwicklung der im Projekt eingesetzten Datenverarbeitungsprozesse leisten.

A Vorläufiger Gliederungsentwurf der Thesis

1. Einleitung

- Problemstellung und Motivation
- Zielsetzung der Arbeit
- Aufbau der Arbeit

2. Grundlagen und Stand der Forschung

- Begriffliche Grundlagen
- Bestehende Ansätze und Abgrenzung

3. Konzeption und Umsetzung des Lösungsansatzes


- LLM-basierter Ansatz
- Regelbasierter Referenzansatz

4. Evaluierung der Ergebnisse

- Evaluationsmethodik und Datensatz
- Vergleich der Ansätze

5. Zusammenfassung und Ausblick

B Vorläufiger Zeit- und Aufgabenplan



C Vorläufiges Literaturverzeichnis

Literatur

- Batini, C. und Scannapieco, M. (2016)
„Data Quality: Concepts, Methodologies and Techniques“. Heidelberg: Springer.
- Boonstra, L. (2023)
„Prompt Engineering“. URL: <https://www.onlinebrandambassadors.com/stable/Google-Prompt-Engineering-Boonstra.pdf> (besucht am 10. 04. 2026).
- Doan, A., Halevy, A. und Ives, Z. (2012)
„Principles of Data Integration“. Waltham, MA: Morgan Kaufmann.
- Ferrara, E., De Meo, P., Fiumara, G. und Baumgartner, R. (2014)
„Web Data Extraction: Applications and Techniques“. Heidelberg: Springer.
- Guha, R. V., Brickley, D. und Macbeth, S. (2016)
„Schema.org: Evolution of Structured Data on the Web“. In: *Communications of the ACM* 59.2, S. 44–51.
- Jansen, T., Liebenow, L. W., Mertens, U., Schmidt, F. T. C., Lohmann, J. F., Fleckenstein, J. und Meyer, J. (2024)
„Data Extraction by Generative Artificial Intelligence: Assessing Determinants of Accuracy Using Human-Extracted Data From Systematic Review Databases“. In: *PsycNet*. URL: <https://psycnet.apa.org/fulltext/2027-04635-004.pdf> (besucht am 20. 04. 2026).
- Meusel, R., Petrovski, P. und Bizer, C. (2015)
„The WebDataCommons Microdata, JSON-LD and RDFa Dataset Series“. In: *Proceedings of the 14th International Semantic Web Conference*.
- Wang, R. Y. und Strong, D. M. (1996)
„Beyond Accuracy: What Data Quality Means to Data Consumers“. In: *Journal of Management Information Systems* 12.4, S. 5–33.
- Yao, S., Yu, D., Zhao, J. et al. (2023)
„Tree of Thoughts: Deliberate Problem Solving with Large Language Models“. In: *arXiv preprint arXiv:2305.10601*. URL: <https://arxiv.org/abs/2305.10601> (besucht am 20. 04. 2026).