



Hochschule
Bonn-Rhein-Sieg
University of Applied Sciences

HOCHSCHULE BONN-RHEIN-SIEG

FACHBEREICH INFORMATIK

Exposé zur Bachelorarbeit

Automatisierte Transformation unstrukturierter Produktdaten mittels großer Sprachmodelle

Konzeption, Implementierung und Evaluation eines auf Sprachmodellen basierenden
Ansatzes im Vergleich zu regelbasierten Verfahren

Autor: Fabian Lohoff

Matrikelnummer: 9051803

Unternehmen: snoopmedia GmbH

Bearbeitungszeitraum: Mai 2026 – August 2026

Betreuer: Prof. Dr. Sascha Alda

Fachlicher Betreuer: Ronald Brenner

14. April 2026

Inhaltsverzeichnis

1 Problemstellung	1
2 Fragestellungen	1
3 Zielsetzung	2
4 Grundlagen und Forschungsstand	2
4.1 Datenintegration und automatisierte Extraktionsverfahren	2
4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke	3
5 Methodik	3
6 Evaluierungsstrategie	4
7 Kontext	5
A Vorläufiger Gliederungsentwurf der Thesis	6
B Vorläufiges Literaturverzeichnis	8

1 Problemstellung

Die zunehmende Digitalisierung und Automatisierung von Geschäftsprozessen führt dazu, dass Unternehmen in großem Umfang Produktdaten aus unterschiedlichen Quellen erfassen und verarbeiten. Insbesondere im Kontext von Web-Crawling entstehen dabei häufig große Mengen an unstrukturierten oder nur schwach strukturierten Textdaten, die für eine Weiterverarbeitung in Informationssystemen zunächst in eine definierte Datenstruktur überführt werden müssen.

Ein zentrales Problem besteht darin, dass diese Rohdaten in der Regel nicht den Anforderungen bestehender Datenbankschemata entsprechen. Die Transformation solcher formlosen Produktinformationen in eine strukturierte und schema-konforme Form erfolgt häufig mittels regelbasierter Ansätze. Diese sind jedoch anfällig gegenüber variierenden Schreibweisen, uneinheitlichen Formaten sowie semantischen Unterschieden und stoßen insbesondere bei heterogenen Datenquellen schnell an ihre Grenzen. Gleichzeitig eröffnen Large Language Models (LLMs) neue Möglichkeiten zur semantischen Interpretation und Strukturierung unstrukturierter Daten. Allerdings ist bislang unklar, inwieweit solche Modelle zuverlässig und konsistent in der Lage sind, komplexe Datenstrukturen vollständig und korrekt abzubilden.

Die Relevanz dieses Problems ergibt sich aus der zentralen Rolle strukturierter Daten für nachgelagerte Prozesse wie Analyse, Suche oder Integration in bestehende Systeme. Eine fehlerhafte oder inkonsistente Datenüberführung kann zu erheblichen Qualitätseinbußen und ineffizienten Prozessen führen. Vor diesem Hintergrund stellt sich die Herausforderung, einen Ansatz zu entwickeln, der sowohl die Flexibilität semantischer Modelle nutzt als auch die Anforderungen an Schema-Konformität und Datenqualität erfüllt. Zudem ist zu untersuchen, wie sich ein solcher Ansatz im Vergleich zu klassischen regelbasierten Verfahren verhält und unter welchen Bedingungen ein praktischer Einsatz sinnvoll ist.

2 Fragestellungen

Die Arbeit soll die folgende zentrale Forschungsfrage beantworten:

Wie gut kann ein LLM-basierter Ansatz formloser Produktdaten vollständig und schema-konform in eine bestehende Datenbankstruktur überführen, und wie schneidet dieser im Vergleich zu einem regelbasierten Ansatz für ein ausgewähltes Datenfeld ab?

Daraus ergeben sich folgende Teilfragestellungen:

1. In welchem Maße gelingt es einem LLM-basierten Ansatz, unstrukturierte Produktdaten korrekt und vollständig auf ein vorgegebenes Datenbankschema abzubilden?
2. Wie hoch ist die Schema-Konformität der durch das LLM erzeugten Daten?
3. Wie unterscheidet sich die Extraktionsqualität eines LLM-basierten Ansatzes gegenüber einem regelbasierten Verfahren für ein Referenzdatenfeld?
4. Welche Auswirkungen haben unterschiedliche Datenformate und Schreibweisen auf die Leistungsfähigkeit der Ansätze?
5. Welche Grenzen und potenziellen Fehlerquellen ergeben sich beim Einsatz von LLMs zur strukturierten Datenüberführung?

3 Zielsetzung

Ziel der vorliegenden Arbeit ist die Entwicklung und Evaluation eines Ansatzes zur automatisierten Transformation unstrukturierter Produktdaten in eine bestehende Datenbankstruktur unter Verwendung von Large Language Models (LLMs).

Im Mittelpunkt steht die Untersuchung, inwieweit ein LLM-basierter Ansatz in der Lage ist, formlos vorliegende Produktinformationen vollständig, konsistent und schema-konform in eine strukturierte Form zu überführen. Dabei soll insbesondere die Leistungsfähigkeit dieses Ansatzes im Vergleich zu einem regelbasierten Verfahren für ein ausgewähltes Referenzdatenfeld analysiert werden.

Zur Erreichung dieses Ziels werden folgende Teilziele verfolgt:

- Entwicklung eines LLM-basierten Ansatzes zur vollständigen Abbildung unstrukturierter Produktdaten
- Implementierung eines regelbasierten Vergleichsansatzes für ein Referenzdatenfeld
- Definition geeigneter Evaluationsmetriken
- Durchführung einer quantitativen Evaluation
- Analyse der Ergebnisse

Abgrenzung des Untersuchungsumfangs:

- Bestandteil der Arbeit ist die Transformation bereits vorhandener Rohdaten.
- Bestandteil der Arbeit ist die Entwicklung und Evaluation eines Mapping-Ansatzes.
- Nicht Bestandteil der Arbeit ist die Entwicklung eines Crawling-Systems.
- Nicht Bestandteil der Arbeit ist die Erweiterung des Datenbankschemas.

4 Grundlagen und Forschungsstand

4.1 Datenintegration und automatisierte Extraktionsverfahren

In einer Vielzahl datengetriebener Anwendungen liegen Informationen initial in unstrukturierter oder schwach strukturierter Form vor, beispielsweise als frei formulierte Textbeschreibungen. Für die effiziente Weiterverarbeitung in Informationssystemen ist eine Überführung dieser Daten in strukturierte Formate notwendig, die einem vordefinierten Datenbankschema entsprechen. Die Transformation unstrukturierter Daten in eine strukturierte Form stellt eine Kernherausforderung der Datenintegration dar. Traditionelle Lösungsansätze stützen sich primär auf regelbasierte Verfahren, bei denen spezifische Muster oder Heuristiken zur Extraktion einzelner Datenfelder definiert werden. Diese Verfahren erweisen sich jedoch als defizitär gegenüber variierenden Schreibweisen, mangelnder Standardisierung sowie semantischer Mehrdeutigkeit und verursachen einen erheblichen manuellen Wartungsaufwand.

Mit der Entwicklung großer Sprachmodelle (engl. *Large Language Models*, kurz LLM) haben sich neue Kapazitäten zur Verarbeitung unstrukturierter Daten eröffnet. Diese Modelle sind in der Lage, natürliche Sprache semantisch zu interpretieren und daraus strukturierte Informationen zu deduzieren. Aktuelle Untersuchungen belegen, dass generative KI-Systeme verstärkt zur automatisierten Datenextraktion herangezogen werden. Die Qualität der extrahierten Informationen wird üblicherweise mittels etablierter Metriken wie *Precision*, *Recall* und dem

F1-Score quantifiziert. Während *Precision* den Anteil korrekt identifizierter Elemente an der Gesamtmenge der Identifizierungen beschreibt, gibt der *Recall* den Anteil korrekt identifizierter Elemente im Verhältnis zu allen tatsächlich relevanten Elementen an. Der *F1-Score* fungiert als harmonisches Mittel dieser Kennzahlen und dient als aggregiertes Maß der Extraktionsgüte (Jansen et al. 2024, S. 1283). Zudem wird die Übereinstimmung mit Referenzdaten häufig über die prozentuale Übereinstimmung oder den Cohen's Kappa-Koeffizienten validiert, welcher statistische Zufallseffekte berücksichtigt (Jansen et al. 2024, S. 1283).

4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke

Die Effektivität großer Sprachmodelle wird maßgeblich durch die Gestaltung der Eingabeaufforderungen gesteuert. Dieser als *Prompt Engineering* bezeichnete Prozess umfasst die strategische Formulierung von Anweisungen zur Kontrolle des Modellverhaltens. Relevante Parameter bei der Textgenerierung sind unter anderem die Temperatur sowie *Top-K*- und *Top-P*-Sampling-Verfahren, welche die Selektion der generierten Token beeinflussen. Während eine niedrige Temperatur deterministischere Resultate begünstigt, führt eine höhere Temperatur zu variableren Ausgaben (Boonstra 2023, S. 9f.). Ergänzend existieren verschiedene Techniken wie *Zero-Shot*- und *Few-Shot-Prompting*, bei denen das Modell ohne beziehungsweise mit wenigen Beispielen operiert. Erweiterte Vorgehensweisen wie das *Chain-of-Thought-Prompting* ermöglichen eine explizite Abbildung von Zwischenschritten im Lösungsprozess, was die Nachvollziehbarkeit und Ergebnisqualität steigern kann (Boonstra 2023, S. 29ff.).

Über klassische Techniken hinaus modellieren neuere Methoden komplexere Entscheidungsprozesse, wie beispielsweise der *Tree of Thoughts* (ToT), welcher Problemstellungen in diskrete Zwischenschritte (*Thoughts*) zerlegt und diese in einer baumartigen Struktur organisiert (Yao et al. 2023, S. 3f.). Dabei werden potenzielle Lösungswege systematisch generiert und mittels Bewertungsstrategien selektiert. Solche Ansätze gestatten eine methodische Exploration des Lösungsraums und bieten insbesondere bei komplexen Transformationsaufgaben Vorteile.

Obgleich große Sprachmodelle vielversprechende Resultate in der Verarbeitung unstrukturierter Daten liefern, ist die Zuverlässigkeit und Konsistenz bei der vollständigen Abbildung komplexer Datenbankschemata nicht hinreichend belegt. Es mangelt insbesondere an systematischen Vergleichen zwischen LLM-basierten Ansätzen und klassischen regelbasierten Verfahren im Kontext einer schema-konformen Datenüberführung. Des Weiteren sind Aspekte der Robustheit gegenüber variierenden Eingabeformaten sowie die Reproduzierbarkeit der Ergebnisse in produktiven Umgebungen unzureichend erforscht. Hieraus resultiert ein wissenschaftlicher Bedarf an einer quantitativen Bewertung und Einordnung der Leistungsfähigkeit von LLMs im Vergleich zu etablierten Standardverfahren.

5 Methodik

Zur Beantwortung der formulierten Fragestellungen wird ein kombinierter Ansatz aus konzeptioneller Entwicklung, prototypischer Implementierung sowie quantitativer Evaluation verfolgt.

Zunächst erfolgt eine systematische Analyse der Ausgangsdaten sowie der Anforderungen des zugrunde liegenden Datenbankschemas. Dabei werden die relevanten Datenfelder, deren Struktur sowie notwendige Transformationen identifiziert. Parallel dazu wird eine Literaturrecherche durchgeführt, um bestehende Ansätze zur Verarbeitung und Strukturierung unstrukturierter Daten sowie den Einsatz von Large Language Models (LLMs) in vergleichbaren Kontexten zu untersuchen.

Aufbauend auf diesen Erkenntnissen wird ein LLM-basierter Ansatz zur Transformation unstrukturierter Produktdaten entwickelt. Dieser umfasst die Konzeption geeigneter Prompts,

die Definition von Mapping-Strategien zwischen Eingabedaten und Zielschema sowie die Implementierung eines prototypischen Systems zur automatisierten Datenüberführung.

Ergänzend wird ein regelbasierter Ansatz für ein ausgewähltes Referenzdatenfeld implementiert. Dieser dient als Baseline und ermöglicht einen direkten Vergleich zwischen klassischen deterministischen Verfahren und dem LLM-basierten Ansatz.

Zur Bewertung der Ansätze wird ein geeigneter Datensatz definiert, der als Referenz (Ground Truth) für die Evaluation dient. Auf dieser Basis erfolgt eine quantitative Analyse anhand definierter Key Performance Indicators (KPIs). Dazu zählen insbesondere die Schema-Konformität der erzeugten Daten, die Vollständigkeit der Abbildung sowie die Genauigkeit der Extraktion für das Referenzdatenfeld. Ergänzend werden Effizienzaspekte wie Laufzeit und Verarbeitungskosten betrachtet.

Die Evaluation erfolgt durch einen systematischen Vergleich der Ergebnisse beider Ansätze. Dabei werden sowohl die Qualität der erzeugten Daten als auch die Robustheit gegenüber variierenden Eingabeformaten analysiert. Abschließend werden die Ergebnisse interpretiert und hinsichtlich ihrer praktischen Einsetzbarkeit sowie ihrer Übertragbarkeit auf vergleichbare Anwendungsfälle bewertet.

6 Evaluierungsstrategie

Zur Überprüfung der Zielerreichung und zur Beantwortung der formulierten Fragestellungen wird eine quantitative Evaluierung der entwickelten Ansätze durchgeführt.

Grundlage der Evaluation bildet ein Referenzdatensatz (Ground Truth), der strukturierte Zielwerte für ausgewählte Produktdaten enthält. Dieser dient als Vergleichsbasis zur Bewertung der durch die Ansätze erzeugten Ergebnisse.

Die Evaluierung erfolgt anhand definierter Key Performance Indicators (KPIs), die sowohl die Qualität als auch die Strukturtreue der erzeugten Daten abbilden:

- **Schema Compliance Rate:** Anteil der generierten Datensätze, die dem vorgegebenen Datenbankschema entsprechen
- **Vollständigkeit (Coverage):** Anteil der korrekt befüllten Datenfelder im Verhältnis zu allen erforderlichen Feldern
- **Konsistenz:** Grad der strukturellen und semantischen Einheitlichkeit der erzeugten Daten
- **Exact Match Rate:** Übereinstimmung der generierten Werte mit dem Ground Truth für das Referenzdatenfeld
- **Precision, Recall und F1-Score:** Bewertung der Extraktionsqualität für das Referenzdatenfeld
- **Effizienzmetriken:** Laufzeit sowie geschätzte Verarbeitungskosten der jeweiligen Ansätze

Zur Vergleichbarkeit wird sowohl der LLM-basierte Ansatz als auch der regelbasierte Ansatz auf denselben Datensatz angewendet. Die Ergebnisse werden anschließend systematisch gegenübergestellt.

Die Auswertung erfolgt in mehreren Schritten: Zunächst werden die einzelnen Metriken berechnet und quantitativ analysiert. Anschließend werden die Ergebnisse interpretiert, um Unterschiede in der Leistungsfähigkeit, Robustheit gegenüber variierenden Eingabeformaten sowie potenzielle Fehlerquellen zu identifizieren.

Darüber hinaus wird untersucht, inwieweit die Ergebnisse auf andere Datensätze oder Anwendungsfälle übertragbar sind. Dabei werden insbesondere die Grenzen des LLM-basierten Ansatzes hinsichtlich Schema-Konformität, Konsistenz und Reproduzierbarkeit berücksichtigt.

Die Evaluierung ermöglicht somit eine fundierte Bewertung der Frage, ob und unter welchen Bedingungen ein LLM-basierter Ansatz gegenüber klassischen regelbasierten Verfahren Vorteile bietet.

7 Kontext

Die vorliegende Arbeit wird im Rahmen eines Forschungsprojekts in Zusammenarbeit mit dem Unternehmen snoopmedia GmbH durchgeführt. Das Projekt bewegt sich im Kontext der automatisierten Verarbeitung und Strukturierung von Produktdaten, insbesondere im Umfeld datengetriebener Anwendungen und digitaler Geschäftsmodelle.

Im Rahmen des Projekts stehen bereits durch eine bestehende Crawling-Pipeline erhobene Rohdaten zur Verfügung, die in Form unstrukturierter Produktinformationen vorliegen. Diese Daten bilden die Grundlage für die in dieser Arbeit untersuchte Transformationsaufgabe. Ziel ist es, diese Informationen in eine bestehende Datenbankstruktur zu überführen, um eine Weiterverarbeitung in nachgelagerten Systemen zu ermöglichen.

Die Arbeit ist dabei in eine bestehende Systemlandschaft eingebettet, die Anforderungen an die Struktur, Konsistenz und Qualität der Daten stellt. Insbesondere ist die Einhaltung eines vorgegebenen Datenbankschemas eine zentrale Rahmenbedingung. Gleichzeitig ergeben sich aus dem praktischen Anwendungskontext Anforderungen an die Robustheit gegenüber heterogenen Datenquellen sowie an die Effizienz der Verarbeitung.

Darüber hinaus ist die Arbeit durch den begrenzten Bearbeitungszeitraum sowie durch die Verfügbarkeit der zugrunde liegenden Daten eingeschränkt. Die Entwicklung und Evaluation des Lösungsansatzes erfolgt daher auf Basis eines definierten Datenausschnitts.

Die Ergebnisse der Arbeit sollen sowohl wissenschaftliche Erkenntnisse im Bereich der automatisierten Datenstrukturierung liefern als auch einen praktischen Beitrag zur Weiterentwicklung der im Projekt eingesetzten Datenverarbeitungsprozesse leisten.

A Vorläufiger Gliederungsentwurf der Thesis

1. Einleitung

- Problemstellung und Motivation
- Zielsetzung der Arbeit
- Aufbau der Arbeit

2. Grundlagen und Stand der Forschung

- Begriffliche Grundlagen
- Bestehende Ansätze und Abgrenzung

3. Konzeption und Umsetzung des Lösungsansatzes


- LLM-basierter Ansatz
- Regelbasierter Referenzansatz

4. Evaluierung der Ergebnisse

- Evaluationsmethodik und Datensatz
- Vergleich der Ansätze

5. Zusammenfassung und Ausblick

B Vorläufiger Zeit- und Aufgabenplan



B Vorläufiges Literaturverzeichnis

Literatur

Boonstra, L. (2023)

„Prompt Engineering“. URL: <https://www.onlinebrandambassadors.com/stable/Google-Prompt-Engineering-Boonstra.pdf> (besucht am 10.04.2026).

Jansen, T., Liebenow, L. W., Mertens, U., Schmidt, F. T. C., Lohmann, J. F., Fleckenstein, J. und Meyer, J. (2024)

„Data Extraction by Generative Artificial Intelligence: Assessing Determinants of Accuracy Using Human-Extracted Data From Systematic Review Databases“. In: *PsycNet*. URL: <https://psycnet.apa.org/fulltext/2027-04635-004.pdf> (besucht am 10.04.2026).

Yao, S., Yu, D., Zhao, J. et al. (2023)

„Tree of Thoughts: Deliberate Problem Solving with Large Language Models“. In: *arXiv preprint arXiv:2305.10601*. URL: <https://arxiv.org/abs/2305.10601> (besucht am 10.04.2026).