



Hochschule
Bonn-Rhein-Sieg
University of Applied Sciences

HOCHSCHULE BONN-RHEIN-SIEG

FACHBEREICH INFORMATIK

Exposé zur Bachelorarbeit in BWI

Entwicklung & Evaluation eines Konzepts zur Automatisierten Transformation unstrukturierter Produktdaten mittels großer Sprachmodelle

05. Mai 2026

Autor: Fabian Lohoff

Matrikelnummer: 9051803

Unternehmen: snoopmedia GmbH

Bearbeitungszeitraum: Mai 2026 – August 2026

Erstprüfer: Prof. Dr. Sascha Alda

Zweitprüfer: Prof. Dr. Raoul Könsgen

Fachlicher Betreuer: Ronald Brenner

Inhaltsverzeichnis

1 Problemstellung	1
2 Fragestellungen	2
3 Zielsetzung	2
4 Grundlagen und Forschungsstand	3
4.1 Datenintegration und automatisierte Extraktionsverfahren	3
4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke	3
5 Methodik	4
6 Evaluierungsstrategie	4
7 Kontext	5
A Vorläufiger Gliederungsentwurf der Thesis	6
B Vorläufiger Zeit- und Aufgabenplan	7
C Vorläufiges Literaturverzeichnis	8

1 Problemstellung

Die zunehmende Digitalisierung und Automatisierung von Geschäftsprozessen führt dazu, dass Unternehmen in großem Umfang Produktdaten aus unterschiedlichen Quellen erfassen und verarbeiten (vgl. Chen et al. 2012, S. 1165f.). Insbesondere im Kontext von Web-Crawling entstehen dabei häufig große Mengen an unstrukturierten oder nur schwach strukturierten Textdaten (vgl. Ferrara et al. 2014, S. 2), die für eine Weiterverarbeitung in Informationssystemen zunächst in eine definierte Datenstruktur überführt werden müssen (vgl. Doan et al. 2012, S. 3).

Ein zentrales Problem besteht darin, dass diese Rohdaten in der Regel nicht den Anforderungen bestehender Datenbankschemata entsprechen. Dies ist primär auf eine mangelnde Standardisierung zurückzuführen. Dies ist eine der Kernherausforderungen innerhalb der Datenintegration (vgl. Doan et al. 2012, S. 1–15). Zwar existieren mit Initiativen wie schema.org fundierte Ansätze, um einen generischen Standard für die semantische Auszeichnung von Webinhalten zu etablieren (vgl. Guha et al. 2016, S. 44), jedoch findet dieser in der Praxis noch keine flächendeckende Anwendung. Infolgedessen bleibt eine signifikante Heterogenität der Datenquellen bestehen, welche die nahtlose Integration in Informationssysteme erschwert (vgl. Meusel et al. 2015, S. 1).

Die Transformation solcher formlosen Produktinformationen in eine strukturierte und schema-konforme Form erfolgt häufig mittels regelbasierter Ansätze. In der Literatur werden diese oft als Wrapper bezeichnet, die auf spezifische Muster oder Heuristiken angewiesen sind (vgl. Ferrara et al. 2014, S. 9). Diese Verfahren erweisen sich jedoch als äußerst fragil gegenüber variierenden Schreibweisen, uneinheitlichen Formaten sowie semantischen Unterschieden (vgl. Ferrara et al. 2014, S. 12). Insbesondere bei heterogenen Datenquellen stoßen sie an ihre Grenzen, da jede strukturelle Abweichung der Quelle eine manuelle Anpassung der Extraktionsregeln erfordert, was in der Praxis zu einem kaum noch zu bewältigenden Wartungsaufwand führt (vgl. Ferrara et al. 2014, S. 14).

Gleichzeitig eröffnen LLMs (Large Language Models, dt. große Sprachmodelle) neue Möglichkeiten zur semantischen Interpretation und Strukturierung unstrukturierter Daten. Allerdings ist bislang unklar, inwieweit solche Modelle zuverlässig und konsistent in der Lage sind, komplexe Datenstrukturen vollständig und korrekt abzubilden. Die Relevanz dieses Problems ergibt sich aus der zentralen Rolle strukturierter Daten für nachgelagerte Prozesse wie Analyse, Suche oder Integration in bestehende Systeme. Eine fehlerhafte oder inkonsistente Datenüberführung kann zu erheblichen Qualitätseinbußen und ineffizienten Prozessen führen.

Vor diesem Hintergrund stellt sich die Herausforderung, einen Ansatz zu entwickeln, der sowohl die Flexibilität semantischer Modelle nutzt als auch die Anforderungen an Schema-Konformität und Datenqualität erfüllt. Zudem ist zu untersuchen, wie sich ein solcher Ansatz im Vergleich zu klassischen regelbasierten Verfahren verhält und unter welchen Bedingungen ein praktischer Einsatz sinnvoll ist.

Diese allgemeinen Herausforderungen zeigen sich unmittelbar in der operativen Praxis der snoopmedia GmbH, insbesondere bei der automatisierten Erfassung von Lebensmittel-Produktdaten. Durch bestehende Crawling-Pipelines werden bereits umfangreiche Rohdaten erhoben, die jedoch als hochgradig heterogene und unstrukturierte Textbausteine, wie Bezeichnungen, komplexe Zutatenlisten oder Nährwertangaben, vorliegen. Die manuelle Überführung dieser Informationen in das streng definierte Ziel-Datenbankschema des Unternehmens ist bei dem stetig wachsenden Datenvolumen ökonomisch nicht skalierbar. Da herkömmliche regelbasierte Verfahren aufgrund der variablen Semantik und Formatierung der Quellseiten einen kaum zu bewältigenden Wartungsaufwand verursachen, besteht eine kritische Lücke in der automatisierten Datenverarbeitungskette.

2 Fragestellungen

Die zentrale Forschungsfrage der Arbeit lautet:

Wie gut kann ein LLM-basierter Ansatz formlose Produktdaten vollständig und schema-konform in eine bestehende Datenbankstruktur überführen, und wie schneidet dieser im Vergleich zu einem regelbasierten Ansatz für ein ausgewähltes Datenfeld ab?

Daraus leiten sich folgende Teilfragestellungen ab:

1. In welchem Maße gelingt es einem LLM-basierten Ansatz, unstrukturierte Produktdaten korrekt und vollständig auf ein vorgegebenes Datenbankschema abzubilden?
2. Wie hoch ist die Schema-Konformität der durch das LLM erzeugten Daten?
3. Wie unterscheidet sich die Extraktionsqualität des LLM-basierten Ansatzes von der eines regelbasierten Verfahrens für ein Referenzdatenfeld?
4. Welche Auswirkungen haben unterschiedliche Datenformate und Schreibweisen auf die Leistungsfähigkeit der Ansätze?
5. Welche Grenzen und Fehlerquellen ergeben sich beim Einsatz von LLMs zur Datenüberführung?

3 Zielsetzung

Ziel der Arbeit ist die Entwicklung und Evaluation eines Ansatzes zur automatisierten Transformation unstrukturierter Produktdaten in eine bestehende Datenbankstruktur unter Verwendung von Large Language Models.

Im Fokus steht die Untersuchung, inwieweit ein LLM-basierter Ansatz formlos vorliegende Produktinformationen vollständig, konsistent und schema-konform strukturieren kann. Dabei wird die Leistungsfähigkeit dieses Ansatzes vergleichend einem regelbasierten Verfahren für ein Referenzdatenfeld gegenübergestellt.

Zur Erreichung dieses Ziels werden folgende Teilziele verfolgt:

- *Entwicklung*: Konzeption eines LLM-basierten Ansatzes zur Datenabbildung.
- *Implementierung*: Umsetzung des LLM-Konzepts und eines regelbasierten Vergleichsansatzes.
- *Evaluation*: Definition geeigneter Metriken und quantitative Untersuchung.
- *Analyse*: Auswertung und Interpretation der Ergebnisse.

Abgrenzung des Untersuchungsumfangs:

- *In Scope*: Transformation bereits vorhandener Rohdaten sowie die Entwicklung und Evaluation des Mapping-Ansatzes.
- *Out of Scope*: Entwicklung eines Crawling-Systems zur Datengewinnung sowie die Erweiterung des bestehenden Datenbankschemas.

4 Grundlagen und Forschungsstand

4.1 Datenintegration und automatisierte Extraktionsverfahren

In einer Vielzahl datengetriebener Anwendungen liegen Informationen initial in unstrukturierter oder schwach strukturierter Form vor, beispielsweise als frei formulierte Textbeschreibungen (vgl. Ferrara et al. 2014, S. 2). Für die effiziente Weiterverarbeitung in Informationssystemen ist eine Überführung dieser Daten in strukturierte Formate notwendig, die einem vordefinierten Datenbankschema entsprechen (vgl. Doan et al. 2012, S. 3). Die Transformation unstrukturierter Daten in eine strukturierte Form stellt eine Kernherausforderung der Datenintegration dar (vgl. Doan et al. 2012, S. 1–15). Traditionelle Lösungsansätze stützen sich primär auf regelbasierte Verfahren, bei denen spezifische Muster oder Heuristiken zur Extraktion einzelner Datenfelder definiert werden (vgl. Ferrara et al. 2014, S. 9). Diese Verfahren erweisen sich jedoch als defizitär gegenüber variierenden Schreibweisen, mangelnder Standardisierung sowie semantischer Mehrdeutigkeit und verursachen einen erheblichen manuellen Wartungsaufwand (vgl. Ferrara et al. 2014, S. 12–14).

Mit der Entwicklung von LLMs haben sich neue Kapazitäten zur Verarbeitung unstrukturierter Daten eröffnet. Diese Modelle sind in der Lage, natürliche Sprache semantisch zu interpretieren und daraus strukturierte Informationen zu deduzieren. Aktuelle Untersuchungen belegen, dass generative KI-Systeme verstärkt zur automatisierten Datenextraktion herangezogen werden (vgl. Jansen et al. 2024). Die Qualität der extrahierten Informationen wird üblicherweise mittels etablierter Metriken wie *Precision*, *Recall* und dem *F1-Score* quantifiziert. Während *Precision* den Anteil korrekt identifizierter Elemente an der Gesamtmenge der Identifizierungen beschreibt, gibt der *Recall* den Anteil korrekt identifizierter Elemente im Verhältnis zu allen tatsächlich relevanten Elementen an. Der *F1-Score* fungiert als harmonisches Mittel dieser Kennzahlen und dient als aggregiertes Maß der Extraktionsgüte (vgl. Jansen et al. 2024, S. 1283). Zudem wird die Übereinstimmung mit Referenzdaten häufig über die prozentuale Übereinstimmung oder den Cohen's Kappa-Koeffizienten validiert, welcher statistische Zufallseffekte berücksichtigt (vgl. Jansen et al. 2024, S. 1283).

4.2 Methodiken der Sprachmodellsteuerung und Forschungslücke

Die Effektivität von LLMs wird maßgeblich durch die Gestaltung der Eingabeaufforderungen gesteuert. Dieser als *Prompt Engineering* bezeichnete Prozess umfasst die strategische Formulierung von Anweisungen zur Kontrolle des Modellverhaltens (vgl. Boonstra 2023, S. 5). Relevante Parameter wie die Temperatur beeinflussen dabei maßgeblich, ob die Ausgaben eher deterministisch oder variabel ausfallen (vgl. Boonstra 2023, S. 9f.). Über klassische Strategien wie *Few-Shot-Prompting* hinaus ermöglichen neuere Methoden wie der *Tree of Thoughts* (ToT) eine systematische Exploration des Lösungsraums durch die Zerlegung komplexer Problemstellungen in diskrete Zwischenschritte (vgl. Yao et al. 2023, S. 3f.).

Ogleich LLMs vielversprechende Resultate in der Verarbeitung unstrukturierter Daten liefern, ist die Zuverlässigkeit und Konsistenz bei der vollständigen Abbildung komplexer Datenbankschemata nicht hinreichend belegt. Aktuelle Untersuchungen weisen darauf hin, dass die Extraktionsgüte von einer Vielzahl von Faktoren abhängt und eine systematische Bewertung der Genauigkeit gegenüber menschlich validierten Referenzdaten weiterhin eine Kernherausforderung darstellt (vgl. Jansen et al. 2024, S. 1283). Es mangelt insbesondere an systematischen Vergleichen zwischen LLM-basierten Ansätzen und klassischen regelbasierten Verfahren im Kontext einer schema-konformen Datenüberführung (vgl. Jansen et al. 2024, S. 1283). Hieraus resultiert der wissenschaftliche Bedarf an einer quantitativen Bewertung der Leistungsfähigkeit von LLMs im Vergleich zu etablierten Standardverfahren.

5 Methodik

Zur Beantwortung der formulierten Fragestellungen wird ein kombinierter Ansatz aus Konzeption, prototypischer Implementierung sowie quantitativer Evaluation verfolgt. Das methodische Vorgehen orientiert sich dabei am Paradigma des Design Science Research, welches die Entwicklung und Evaluation innovativer IT-Artefakte zur Lösung relevanter Praxisprobleme in den Mittelpunkt stellt (vgl. Hevner et al. 2004, S. 77).

In der *Konzeptionsphase* erfolgt zunächst eine systematische Anforderungsanalyse. Die Erhebung und Analyse der Aufgaben wird dabei agil über User Stories abgebildet, um die funktionalen und nicht-funktionalen Anforderungen an die strukturierte Datenüberführung präzise zu spezifizieren (vgl. Cohn 2004, S. 17ff.). Parallel dazu wird eine systematische Literaturrecherche nach etablierten methodischen Standards durchgeführt (vgl. Webster und Watson 2002), um bestehende Ansätze zur Verarbeitung unstrukturierter Daten sowie den Einsatz von LLMs zu untersuchen. Aufbauend auf diesen Erkenntnissen wird die Softwarearchitektur für den LLM-basierten Ansatz entworfen. Hierbei werden etablierte Prinzipien der Architekturentwicklung angewendet (vgl. Starke 2014), um eine nahtlose Integration in bestehende Systeme zu gewährleisten.

In der anschließenden *Implementierungsphase* wird der konzipierte LLM-basierte Ansatz in Form eines Software-Prototyps umgesetzt. Dies umfasst das Prompt Engineering, die Definition von Mapping-Strategien zwischen Eingabedaten und Zielschema sowie die technische Anbindung. Ergänzend wird ein regelbasierter Ansatz für ein ausgewähltes Referenzdatenfeld implementiert. Dieser dient als Baseline und ermöglicht einen direkten Vergleich zwischen klassischen deterministischen Verfahren und dem LLM-basierten Ansatz.

6 Evaluierungsstrategie

Zur Überprüfung der Zielerreichung und zur Beantwortung der formulierten Fragestellungen wird eine quantitative Evaluierung der entwickelten Ansätze durchgeführt.

Grundlage der Evaluation bildet ein repräsentativer Referenzdatensatz (Ground Truth), der strukturierte Zielwerte für ausgewählte Produktdaten enthält. Auf dieser Basis erfolgt ein systematischer Vergleich beider Ansätze hinsichtlich der Qualität der erzeugten Daten sowie der Robustheit gegenüber variierenden Eingabeformaten.

Die Auswertung erfolgt anhand definierter Key Performance Indicators (KPIs), die sowohl die Qualität als auch die Strukturtreue abbilden. Dabei orientiert sich die Auswahl an etablierten Dimensionen der Datenqualität (vgl. Wang und Strong 1996, S. 5–33):

- *Schema Compliance Rate*: Anteil der generierten Datensätze, die dem vorgegebenen Datenbankschema entsprechen (Dimension der *Representational Consistency*).
- *Vollständigkeit (Coverage)*: Anteil der korrekt befüllten Datenfelder im Verhältnis zu allen erforderlichen Feldern (Dimension der *Completeness*, vgl. Batini und Scannapieco 2016, S. 24).
- *Konsistenz*: Grad der strukturellen und semantischen Einheitlichkeit der erzeugten Daten. Diese Metrik validiert die Widerspruchsfreiheit innerhalb der extrahierten Datensätze (vgl. Batini und Scannapieco 2016, S. 31).
- *Exact Match Rate*: Strikte Übereinstimmung der generierten Werte mit dem Ground Truth. Diese binäre Metrik wird häufig zur Evaluation von Extraktionsaufgaben in strukturierten Benchmarks herangezogen (vgl. Jansen et al. 2024, S. 1283).

- *Precision, Recall und F1-Score*: Aggregierte Maße der Extraktionsgüte, wobei Precision die Genauigkeit und Recall die Trefferquote beschreibt (vgl. Jansen et al. 2024, S. 67f.).
- *Effizienzmetriken*: Ergänzend werden Effizienzaspekte wie Laufzeit und Verarbeitungskosten betrachtet, was insbesondere im betrieblichen Kontext von hoher Relevanz ist (vgl. Ferrara et al. 2014, S. 3).

Abschließend werden die Ergebnisse interpretiert und hinsichtlich ihrer praktischen Einsetzbarkeit sowie ihrer Übertragbarkeit auf vergleichbare Anwendungsfälle bewertet.

7 Kontext

Die vorliegende Arbeit erfolgt in Kooperation mit der snoopmedia GmbH und nutzt Ergebnisse sowie Infrastrukturen aus einem vorangegangenen Forschungsprojekt. Im Rahmen dieser Zusammenarbeit steht eine etablierte Crawling-Pipeline sowie ein umfangreicher Datensatz an Rohdaten aus dem Bereich der Lebensmittel-Produktinformationen zur Verfügung. Die Arbeit ist dabei in eine bestehende Systemlandschaft eingebettet, wodurch die Anforderungen an die Struktur und Qualität der Zielformate bereits fest definiert sind. Die Evaluation des zu entwickelnden Lösungsansatzes erfolgt auf Basis eines repräsentativen Datenausschnitts aus diesem Bestand.

A Vorläufiger Gliederungsentwurf der Thesis

1. Einleitung

- 1.1 Problemstellung und Motivation
- 1.2 Zielsetzung und Forschungsfragen
- 1.3 Aufbau der Arbeit

2. Grundlagen und Stand der Forschung

- 2.1 Begriffliche Grundlagen und Datenqualität
- 2.2 Technologische Grundlagen (Large Language Models)
- 2.3 Verwandte Arbeiten und Identifikation der Forschungslücke

3. Konzeption des Lösungsansatzes

- 3.1 Anforderungsanalyse
 - 3.1.1 Analyse der Quelldaten und des Zielschemas
 - 3.1.2 Funktionale und nicht-funktionale Anforderungen
- 3.2 Systemarchitektur und Design
 - 3.2.1 Komponenten der Transformations-Pipeline
 - 3.2.2 Design der Prompt-Hierarchien und Mapping-Logik

4. Implementierung

- 4.1 Realisierung des LLM-basierten Prototyps
- 4.2 Implementierung des regelbasierten Referenzansatzes
- 4.3 Qualitätssicherung und Fehlerbehandlung


5. Evaluierung der Ergebnisse

- 5.1 Evaluationsmethodik
 - 5.1.1 Testdatensatz und Ground Truth
 - 5.1.2 Festlegung der Key Performance Indicators (KPIs)
- 5.2 Ergebnisanalyse und Vergleich
 - 5.2.1 Analyse der Extraktionsgüte und Konformität
 - 5.2.2 Gegenüberstellung: LLM vs. Regelbasiert

6. Zusammenfassung und Ausblick

- 6.1 Fazit zur Zielerreichung
- 6.2 Kritische Würdigung und Forschungsausblick

B Vorläufiger Zeit- und Aufgabenplan



C Vorläufiges Literaturverzeichnis

Literatur

- Batini, C. und Scannapieco, M. (2016)
„Data Quality“. 1. Aufl. Heidelberg: Springer.
- Boonstra, L. (2023)
„Prompt Engineering“. URL: <https://www.onlinebrandambassadors.com/stable/Google-Prompt-Engineering-Boonstra.pdf> (besucht am 10. 04. 2026).
- Chen, H., Chiang, R. H. L. und Storey, V. C. (2012)
„Business Intelligence and Analytics: From Big Data to Big Impact“. In: *MIS Quarterly* 36.4, S. 1165–1188.
- Cohn, M. (2004)
„User Stories Applied: For Agile Software Development“. 1. Aufl. Boston, MA: Addison-Wesley Professional.
- Doan, A., Halevy, A. und Ives, Z. (2012)
„Principles of Data Integration“. 1. Aufl. Waltham, MA: Morgan Kaufmann.
- Ferrara, E., De Meo, P., Fiumara, G. und Baumgartner, R. (2014)
„Web Data Extraction: Applications and Techniques: A Survey“. In: *Knowledge-Based Systems* 70, S. 301–323.
- Guha, R. V., Brickley, D. und Macbeth, S. (2016)
„Schema.org: Evolution of Structured Data on the Web“. In: *Communications of the ACM* 59.2, S. 44–51.
- Hevner, A. R., March, S. T., Park, J. und Ram, S. (2004)
„Design Science in Information Systems Research“. In: *MIS Quarterly* 28.1, S. 75–105.
- Jansen, T., Liebenow, L. W., Mertens, U., Schmidt, F. T. C., Lohmann, J. F., Fleckenstein, J. und Meyer, J. (2024)
„Data Extraction by Generative Artificial Intelligence: Assessing Determinants of Accuracy Using Human-Extracted Data From Systematic Review Databases“. In: *PsycNet*. URL: <https://psycnet.apa.org/fulltext/2027-04635-004.pdf> (besucht am 20. 04. 2026).
- Meusel, R., Petrovski, P. und Bizer, C. (2015)
„The WebDataCommons Microdata, JSON-LD and RDFa Dataset Series“. In: *Proceedings of the 14th International Semantic Web Conference*. Bethlehem, PA, USA.
- Starke, G. (2014)
„Effektive Softwarearchitekturen: Ein praktischer Leitfaden“. 6. Aufl. München: Carl Hanser Verlag.
- Wang, R. Y. und Strong, D. M. (1996)
„Beyond Accuracy: What Data Quality Means to Data Consumers“. In: *Journal of Management Information Systems* 12.4, S. 5–33.
- Webster, J. und Watson, R. T. (2002)
„Analyzing the Past to Prepare for the Future: Writing a Literature Review“. In: *MIS Quarterly* 26.2, S. xiii–xxiii.
- Yao, S., Yu, D., Zhao, J. et al. (2023)
„Tree of Thoughts: Deliberate Problem Solving with Large Language Models“. In: *arXiv preprint arXiv:2305.10601*. URL: <https://arxiv.org/abs/2305.10601> (besucht am 20. 04. 2026).